Algorithmen und Datenstrukturen Vorlesung #08 – Minimale Spannbäume



Benjamin Blankertz

Lehrstuhl für Neurotechnologie, TU Berlin



benjamin.blankertz@tu-berlin.de

05 · Jun · 2019

Themen der heutigen Vorlesung

- Gewichtete Graphen
- Bestimmung minimaler Spannbäume (minimal spanning tree, MST) in gewichteten ungerichteten Graphen
- Schnitte und kreuzende Kanten
- Ansätze zur Bestimmung von MST
 - Generischer Ansatz
 - Prims Algorithmus
 - Reverse-delete Algorithmus
 - Kruskals Algorithmus
- ▶ UnionFind Algorithmus, von einfach zu effizient zur Verwendung in Kruskal

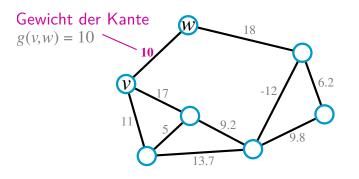
Gewichtete Graphen

- Für die Modellierung vieler praktischer Probleme ist es wichtig, den Kanten eines Graphen Gewichte (oder Kosten) zuordnen zu können.
- ▶ Dies können z. B. die Längen der Streckenabschnitte oder die Fahrkosten sein.
- ▶ Dafür benutzen wir **gewichtete Graphen** und in der nächsten Vorlesung gewichtete Digraphen.

Gewichtete Graphen

- Für die Modellierung vieler praktischer Probleme ist es wichtig, den Kanten eines Graphen Gewichte (oder Kosten) zuordnen zu können.
- ▶ Dies können z. B. die Längen der Streckenabschnitte oder die Fahrkosten sein.
- ▶ Dafür benutzen wir **gewichtete Graphen** und in der nächsten Vorlesung gewichtete Digraphen.
- ► Jeder Kante des Graphen wird ein Gewicht zugeordnet. Man kann auch Knoten-gewichtete Graphen betrachten.

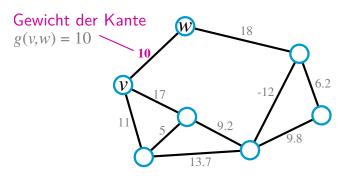
Kantengewichtete Graphen



- ► Formal schreiben wir g(v, w) oder weight(v, w) für das
 Gewicht der Kante (v, w).
- Es sind auch negative Gewichte erlaubt.

TUB AlgoDat 2019 ⊲ 3 ⊳

Kantengewichtete Graphen



- Formal schreiben wir g(v, w) oder weight(v, w) für das
 Gewicht der Kante (v, w).
- Es sind auch negative Gewichte erlaubt.

Änderung in der Implementation gegenüber ungewichteten Graphen:

- ▶ Wir führen eine Klasse für gewichtete Kanten ein, die die beiden Knoten, sowie das Gewicht enthält.
- ► Anstelle von Adjazenzlisten gibt es Inzidenzlisten, die für jeden Knoten die inzidenten Kanten erhalten.

▶ Jede Kante ist doppelt gespeichert, in den Inzidenzlisten beider Knoten.

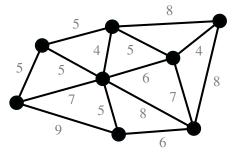
TUB AlgoDat 2019 ⊲ 3 ⊳

API für einen kantengewichteten Graphen

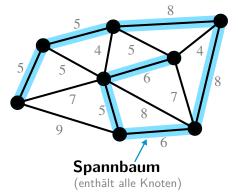
API für eine gewichtete Kante			
public class Edge implements Comparable < Edge >			
	Edge(int v, int w, double weight)	Kante v-w mit Gewicht weight	
double	weight()	Gewicht der Kante	
int	either()	Einer der beiden Knoten dieser Kante	
int	other(int v)	Der Knoten, der nicht v ist	
int	compareTo(Edge that)	Vergleich nach Gewicht	

API für einen kantengewichteten Graphen				
public class EdgeWeightedGraph				
	EdgeWeightedGraph(int V)	Erzeugt leeren Graphen mit V Knoten		
int	V()	Anzahl der Knoten		
void	addEdge(Edge e)	Füge Kante e zum Graphen hinzu		
Iterable <edge></edge>	adj(int v)	Kanten inzident zu v		
Iterable <edge></edge>	edges()	Alle Kanten dieses Graphen		

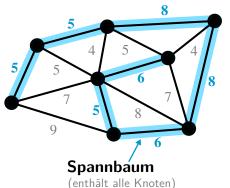
Gewichteter Graph



Gewichteter Graph



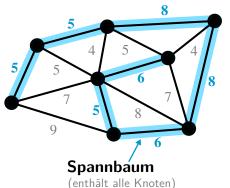
Gewichteter Graph



Gewicht des Spannbaums:

$$5 + 5 + 8 + 8 + 6 + 5 + 6 = 43$$

Gewichteter Graph

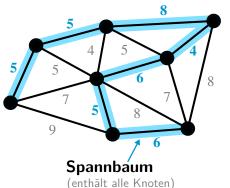


Gewicht des Spannbaums:

$$5 + 5 + 8 + 8 + 6 + 5 + 6 = 43$$

Ein Spannbaum hat immer V-1 Kanten. Gibt es einen mit weniger Gewicht?

Gewichteter Graph

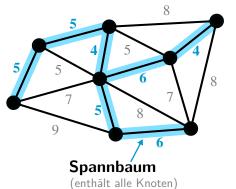


Gewicht des Spannbaums:

$$5 + 5 + 8 + 4 + 6 + 5 + 6 = 39$$

Ein Spannbaum hat immer *V*-1 Kanten. Gibt es einen mit weniger Gewicht?

Gewichteter Graph

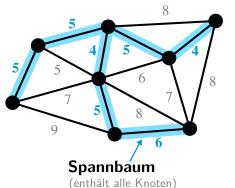


Gewicht des Spannbaums:

$$5 + 5 + 4 + 4 + 6 + 5 + 6 = 35$$

Ein Spannbaum hat immer V-1 Kanten. Gibt es einen mit weniger Gewicht?

Gewichteter Graph

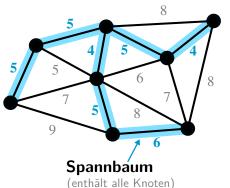


Gewicht des Spannbaums:

$$5 + 5 + 4 + 4 + 5 + 5 + 6 = 34$$

Minimaler Spannbaum?

Gewichteter Graph



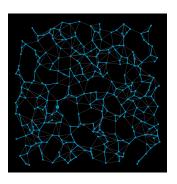
Gewicht des Spannbaums:

$$5 + 5 + 4 + 4 + 5 + 5 + 6 = 34$$

Minimaler Spannbaum?

- ▶ Die Bestimmung minimaler Spannbäume ist für vielen Anwendungen in der Praxis wichtig.
- Ein Graph mit V Knoten und allen möglichen Kanten hat V^{V-2} Spannbäume (Cayley, 1889). Wir brauchen also einen effizienten Algorithmus, kein brute force.

Minimale Spannbäume in der Praxis

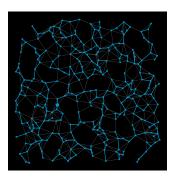


- Der erste Algorithmus zur Bestimmung eines mimimalen Spannbaums geht auf eine Arbeit des Tschechischen Mathematikers Borůvka von 1926 zurück.
- ► Er entwickelte das Verfahren zur optimierten Planung des elektrischen Netzwerkes von Mähren (südöstlicher Teil der Tschechischen Republik).

TUB AlgoDat 2019

d 6 ⊳

Minimale Spannbäume in der Praxis



- Der erste Algorithmus zur Bestimmung eines mimimalen Spannbaums geht auf eine Arbeit des Tschechischen Mathematikers Borůvka von 1926 zurück.
- Er entwickelte das Verfahren zur optimierten Planung des elektrischen Netzwerkes von Mähren (südöstlicher Teil der Tschechischen Republik).
- Heute werden minimale Spannbäume in vielen Bereichen eingesetzt, z.B. Clusteranalyse, Gesichtserkennung, Bildbearbeitung, allgemeines Netzwerkdesign.
- Darüber hinaus werden die Algorithmen zur approximativen Lösung von NP-harten Problemen benutzt.

TUB AlgoDat 2019

d 6 ⊳

Spannendes über Spannbäume

Sei T = (V, E') ein Subgraph von G(V, E). Dann ist T genau dann ein Spannbaum von G, wenn eine (und damit alle) der folgenden, äquivalenten Bedingungen erfüllt ist:

- ▶ Jedes Knotenpaar von *T* ist durch genau einen einfachen Pfad verbunden.
- ▶ T hat V-1 Kanten und ist zusammenhängend.
- ▶ T hat V-1 Kanten und ist azyklisch.
- ▶ *T* ist azyklisch und das Hinzufügen einer beliebigen Kante erzeugt einen Zyklus.
- ► *T* ist zusammenhängend und das Entfernen einer beliebigen Kante macht ihn unzusammenhängend.
- ► *T* ist azyklisch und zusammenhängend.

Allgemeines Vorgehen

- ▶ Das globale Optimierungsproblem kann durch iterierte Sicherstellung einer lokalen Eigenschaft mit einem *greedy* Ansatz gelöst werden.
- ▶ Wir werden zunächst einen allgemeinen Ansatz formulieren und dann zu konkreten Algorithmen für eine geeignete Kantenauswahl fortschreiten.

TUB AlgoDat 2019 ⊲ 8 ⊳

Allgemeines Vorgehen

- ▶ Das globale Optimierungsproblem kann durch iterierte Sicherstellung einer lokalen Eigenschaft mit einem *greedy* Ansatz gelöst werden.
- Wir werden zunächst einen allgemeinen Ansatz formulieren und dann zu konkreten Algorithmen für eine geeignete Kantenauswahl fortschreiten.
- ▶ Wir setzen im Folgenden voraus, dass der gegebene Graph zusammenhängend ist. Andernfalls wendet man die Algorithmen auf seine Zusammenhangskomponenten an und erhält einen minimalen Spannwald.

TUB AlgoDat 2019 ⊲ 8 ⊳

Schnitte durch Graphen

- ightharpoonup Ein Schnitt durch einen Graphen G = (V, E) teilt seine Knoten in zwei nicht-leere Teilgraphen.
- ► Konkret beschreiben wir einen Schnitt durch eine Teilmenge $S \subseteq V$ mit der Eigenschaft, dass (S, E_S) und $(V S, E_{V-S})$ nicht-leere Graphen sind.
- Dabei bezeichnet E_S die Menge aller derjenigen Kanten von G, die in S liegen:

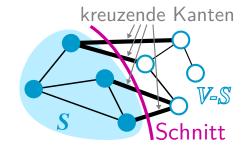
$$E_S := \{(v, w) \in E \mid v \in S \& w \in S\}$$

Schnitte durch Graphen

- ightharpoonup Ein Schnitt durch einen Graphen G = (V, E) teilt seine Knoten in zwei nicht-leere Teilgraphen.
- ▶ Konkret beschreiben wir einen Schnitt durch eine Teilmenge $S \subseteq V$ mit der Eigenschaft, dass (S, E_S) und $(V S, E_{V-S})$ nicht-leere Graphen sind.
- ▶ Dabei bezeichnet E_S die Menge aller derjenigen Kanten von G, die in S liegen:

$$E_S := \{(v, w) \in E \mid v \in S \& w \in S\}$$

Kanten mit einem Knoten innerhalb und einem Knoten außerhalb von S heißen kreuzende Kanten. Diejenigen der kreuzenden Kanten, die minimales Gewicht haben, heißen minimal kreuzende Kanten.



Schnitteigenschaft

Schnitteigenschaft

Sei ein beliebiger Schnitt durch einen Graphen gegeben. Jeder minimale Spannbaum des Graphen muss eine der minimal kreuzenden Kanten enthalten.

Beweis.

- Wir nehmen an, dass es einen MST gibt, der zu dem gegebenen Schnitt keine der minimal kreuzenden Kanten enthält.
- Sei (v, w) eine minimal kreuzende Kante und \boldsymbol{B} der MST plus Kante (v, w). Da der MST schon alle Knoten verbunden hat, entsteht so ein Zyklus und

Schnitteigenschaft

Schnitteigenschaft

Sei ein beliebiger Schnitt durch einen Graphen gegeben. Jeder minimale Spannbaum des Graphen muss eine der minimal kreuzenden Kanten enthalten.

Beweis.

- Wir nehmen an, dass es einen MST gibt, der zu dem gegebenen Schnitt keine der minimal kreuzenden Kanten enthält.
- Sei (v, w) eine minimal kreuzende Kante und \boldsymbol{B} der MST plus Kante (v, w). Da der MST schon alle Knoten verbunden hat, entsteht so ein Zyklus und
- \triangleright ... es muss eine weitere kreuzende Kante des MST geben, die an dem Zyklus beteiligt ist, sagen wir (t, u).
- Wenn (t, u) aus B entfernt wird, bleibt B zusammenhängend und ist also ein Spannbaum.

TUB AlgoDat 2019

⊲ 10 ⊳

Schnitteigenschaft

Schnitteigenschaft

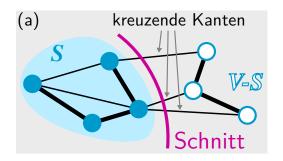
Sei ein beliebiger Schnitt durch einen Graphen gegeben. Jeder minimale Spannbaum des Graphen muss eine der minimal kreuzenden Kanten enthalten.

Beweis.

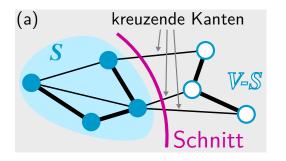
- Wir nehmen an, dass es einen MST gibt, der zu dem gegebenen Schnitt keine der minimal kreuzenden Kanten enthält.
- Sei (v, w) eine minimal kreuzende Kante und \boldsymbol{B} der MST plus Kante (v, w). Da der MST schon alle Knoten verbunden hat, entsteht so ein Zyklus und
- \triangleright ... es muss eine weitere kreuzende Kante des MST geben, die an dem Zyklus beteiligt ist, sagen wir (t, u).
- Wenn (t, u) aus B entfernt wird, bleibt B zusammenhängend und ist also ein Spannbaum.
- ▶ Da (v, w) ein kleineres Gewicht als (t, u) hat, ist der neue Spannbaum leichter als der ursprüngliche, was der Annahme widerspricht, dass es ein MST war.

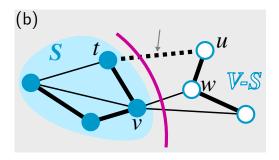
TUB AlgoDat 2019

□ 10 >



(a) Der MST muss eine der kreuzende Kanten enthalten.

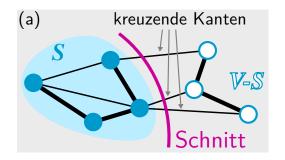


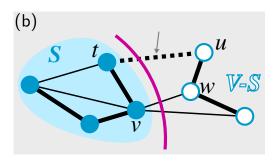


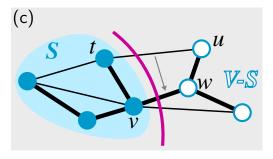
- (a) Der MST muss eine der kreuzende Kanten enthalten.
- (b) Wir nehmen an, es ist (t, u) und nicht die minimale Kante (v, w).

TUB AlgoDat 2019

⊲ 11 ⊳



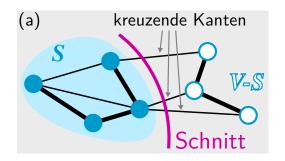


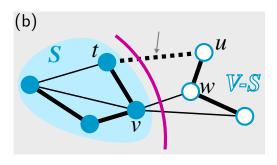


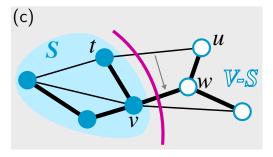
- (a) Der MST muss eine der kreuzende Kanten enthalten.
- (b) Wir nehmen an, es ist (t, u) und nicht die minimale Kante (v, w).
- (c) Weglassen von (t, u) und Hinzufügen von (v, w) erhält Spannbaum-Eigenschaft und verringert das Gewicht.

TUB AlgoDat 2019

⊲ 11 ▷







- (a) Der MST muss eine der kreuzende Kanten enthalten
- (b) Wir nehmen an, es ist (t, u) und nicht die minimale Kante (v, w).
- (c) Weglassen von (t, u) und Hinzufügen von (v, w) erhält Spannbaum-Eigenschaft und verringert das Gewicht.

Also muss (v, w) im MST enthalten sein.

Allgemeiner Ansatz für minimal Spannbäume

Listing 1: Generischer Algorithmus zur Bestimmung eines MST

```
    ME ←Ø
    while ME ist kein Spannbaum
    wähle einen Schnitt S, der keine kreuzende Kante in ME hat
    füge eine minimal kreuzende Kante (v, w) zu ME hinzu
    end
    // ME ist der minimale Spannbaum
```

▶ Bei diesem allgemein Ansatz bleibt offen, wie der Schnitt S zu wählen ist.

TUB AlgoDat 2019

⊲ 12 ▷

Korrektheit des allgemeinen Ansatzes für minimal Spannbäume

Korrektheit des allgemeinen Ansatzes

Der MST Algorithmus in Listing 1 bestimmt einen minimalen Spannbaum

Beweis.

- ▶ Nach der Schnitteigenschaft (Seite 10) ist jede hinzugefügte Kante Teil des MST.
- ▶ Zu zeigen bleibt, dass alle Kanten des MST ausfindig gemacht werden.

TUB AlgoDat 2019

⊲ 13 ⊳

Korrektheit des allgemeinen Ansatzes für minimal Spannbäume

Korrektheit des allgemeinen Ansatzes

Der MST Algorithmus in Listing 1 bestimmt einen minimalen Spannbaum

Beweis.

- ▶ Nach der Schnitteigenschaft (Seite 10) ist jede hinzugefügte Kante Teil des MST.
- ▶ Zu zeigen bleibt, dass alle Kanten des MST ausfindig gemacht werden.
- Wäre dies nicht der Fall, dann stellen die Kanten ME keinen Spannbaum von G dar. Es gibt also mindestens eine nicht leere Zusammenhangskomponente von ME, die nicht ganz G ist.
- ▶ Wir wählen eine dieser Zusammenhangskomponenten als S. Für den durch S definierten Schnitt sind keine der kreuzenden Kanten in ME. Also würde der Pseudocode eine weitere Kante auswählen. □

► Prims Algorithmus.

► Reverse-Delete Algorithmus.

► Kruskals Algorithmus.

TUB AlgoDat 2019

⊲ 14 ⊳

- ▶ Prims Algorithmus. Bilde einen Baum ausgehend von einem Startknoten s. Wähle unter den kreuzenden Kanten eine mit geringstem Gewicht.
- ► Reverse-Delete Algorithmus.
- Kruskals Algorithmus.

TUB AlgoDat 2019

⊲ 14 ⊳

- ▶ Prims Algorithmus. Bilde einen Baum ausgehend von einem Startknoten s. Wähle unter den kreuzenden Kanten eine mit geringstem Gewicht.
- ▶ Reverse-Delete Algorithmus. Durchlaufe die Kanten nach absteigendem Gewicht. Lösche eine Kante, falls sie den Graphen nicht unzusammenhängend macht.
- ► Kruskals Algorithmus.

TUB AlgoDat 2019

⊲ 14 ⊳

- ▶ Prims Algorithmus. Bilde einen Baum ausgehend von einem Startknoten s. Wähle unter den kreuzenden Kanten eine mit geringstem Gewicht.
- ▶ Reverse-Delete Algorithmus. Durchlaufe die Kanten nach absteigendem Gewicht. Lösche eine Kante, falls sie den Graphen nicht unzusammenhängend macht.
- ▶ Kruskals Algorithmus. Durchlaufe die Kanten nach aufsteigendem Gewicht. Füge eine Kante hinzu, wenn sie keinen Zyklus mit den bisher gewählten Kanten bildet.

Prims Algorithmus für minimale Spannbäume

- Markiere den zufällig gewählten Startknoten.
- ► Wähle eine minimal kreuzende Kante bezüglich des Schnittes, der durch den markierten Bereich definiert wird (Startknoten markiert, Endknoten nicht)

▶ Iteriere dies, bis V - 1 Kanten ausgewählt wurden.

TUB AlgoDat 2019

⊲ 15 ▷

Prims Algorithmus für minimale Spannbäume

- Markiere den zufällig gewählten Startknoten.
- ► Wähle eine minimal kreuzende Kante bezüglich des Schnittes, der durch den markierten Bereich definiert wird (Startknoten markiert, Endknoten nicht)
- ▶ Iteriere dies, bis V 1 Kanten ausgewählt wurden.

Wie wird die Kante ausgewählt?

lacktriangle Alle Kanten zu durchsuchen, hätte eine Laufzeit in ${\bf \emph{O}}(E)$.

TUB AlgoDat 2019

⊲ 15 ▷

Prims Algorithmus für minimale Spannbäume

- Markiere den zufällig gewählten Startknoten.
- ► Wähle eine minimal kreuzende Kante bezüglich des Schnittes, der durch den markierten Bereich definiert wird (Startknoten markiert, Endknoten nicht)
- ▶ Iteriere dies, bis V 1 Kanten ausgewählt wurden.

Wie wird die Kante ausgewählt?

- ▶ Alle Kanten zu durchsuchen, hätte eine Laufzeit in O(E).
- Effizienter ist es, alle in Frage kommenden Kanten in eine Vorrangwarteschlange einzufügen und daraus jeweils diejenige mit geringstem Gewicht zu entnehmen: Die Laufzeit ist in $O(\log E)$.

TUB AlgoDat 2019

□ 15 ▷

Erste Implementation von Prims Algorithmus für MST

```
public class MSTPrim {
     protected double[] dist;
     protected PriorityOueue<Edge> pg:
     public MSTPrim(WeightedGraph G) {
5
       marked = new boolean[G,V()]:
       parent = new int[G.V()];
       pq = new PriorityQueue<Edge>(G.V());
                                 // Startknoten 0
10
       visit(G, 0);
       while (!pq.isEmpty()) {
11
         // hole minimal kreuzende Kante aus po
12
13
         Edge e = pa.poll():
         int v = e.either();
14
         int w = e.other(v);
         // prüfe, ob w immer noch unmarkiert,
16
         // also e eine kreuzende Kante ist
18
         if (!marked[w]) {
           parent[w] = v;
19
           visit(G, w);
20
         } else if (!marked[v]) { // dito für v
21
           parent[v] = w;
23
           visit(G, v);
24
25
26
```

 Diese Implementation speichert den MST des Graphen G in dem Vorgängerarray parent.

Korrektheit des Prim Algorithmus

Korrektheit des Prim Algorithmus mit Priority Queue

Die Implementation des Prim Algorithmus mit Priority Queue bestimmt den minimalen Spannbaum in einer Laufzeit in $O(E \log E)$ und Speicherbedarf in O(V + E).

Beweis.

▶ Die Korrektheit folgt aus dem Satz zu dem allgemeinen Ansatz (Seite 13). Dafür ist zu zeigen, dass Prim immer eine minimal kreuzende Kante auswählt.

TUB AlgoDat 2019

□ 17 ▷

Korrektheit des Prim Algorithmus

Korrektheit des Prim Algorithmus mit Priority Queue

Die Implementation des Prim Algorithmus mit Priority Queue bestimmt den minimalen Spannbaum in einer Laufzeit in $O(E \log E)$ und Speicherbedarf in O(V + E).

Beweis.

- ▶ Die Korrektheit folgt aus dem Satz zu dem allgemeinen Ansatz (Seite 13). Dafür ist zu zeigen, dass Prim immer eine minimal kreuzende Kante auswählt.
- ▶ Die Menge der markierten Knoten definiert einen Schnitt.
- ▶ In die Warteschlange werden nur kreuzende Kanten eingefügt (Zeile 33-34), und von diesen wird per PQ diejenige mit geringstem Gewicht ausgewählt (Zeile 13).
- ▶ Bei der Auswahl werden diejenigen Kanten verworfen, deren zweiter Knoten mittlerweile markiert wurde (Zeilen 18 und 21).
- Daher wird immer eine minimal kreuzende Kante ausgewählt.

TUB AlgoDat 2019

□ 17 ▷

Korrektheit des Prim Algorithmus

Korrektheit des Prim Algorithmus mit Priority Queue

Die Implementation des Prim Algorithmus mit Priority Queue bestimmt den minimalen Spannbaum in einer Laufzeit in $O(E \log E)$ und Speicherbedarf in O(V + E).

Beweis.

- ▶ Die Korrektheit folgt aus dem Satz zu dem allgemeinen Ansatz (Seite 13). Dafür ist zu zeigen, dass Prim immer eine minimal kreuzende Kante auswählt.
- ▶ Die Menge der markierten Knoten definiert einen Schnitt.
- ▶ In die Warteschlange werden nur kreuzende Kanten eingefügt (Zeile 33-34), und von diesen wird per PQ diejenige mit geringstem Gewicht ausgewählt (Zeile 13).
- ▶ Bei der Auswahl werden diejenigen Kanten verworfen, deren zweiter Knoten mittlerweile markiert wurde (Zeilen 18 und 21).
- ▶ Daher wird immer eine minimal kreuzende Kante ausgewählt. □
- ▶ Die Laufzeit wird auf der folgenden Seite bestimmt.

TUB AlgoDat 2019

□ 17 ▷

Laufzeit des Prim Algorithmus mit Priority Queue

- ▶ Die Initialisierung hat eine Laufzeit in O(V).
- Die Methode visit() wird für jeden Knoten maximal einmal aufgerufen. Denn der Aufruf geschieht nur für unmarkierte Knoten, der sodann in der Methode markiert wird.
- Daher gelangt jede Kante höchstens einmal in die Warteschlange.

TUB AlgoDat 2019

□ 18 ▷

Laufzeit des Prim Algorithmus mit Priority Queue

- ▶ Die Initialisierung hat eine Laufzeit in O(V).
- Die Methode visit() wird für jeden Knoten maximal einmal aufgerufen. Denn der Aufruf geschieht nur für unmarkierte Knoten, der sodann in der Methode markiert wird.
- ▶ Daher gelangt jede Kante höchstens einmal in die Warteschlange.
- Die Methoden isEmpty(), poll() und add() der Priority Queue werden also höchstens E-mal aufgerufen.
- Die Methoden isEmpty() und poll() haben konstante Laufzeit.
- ▶ Da höchstens E Elemente (Kanten) in die Warteschlange eingefügt werden, hat add() eine Laufzeit in $O(\log E)$, siehe Vorlesung #3.

TUB AlgoDat 2019

□ 18 ▷

Laufzeit des Prim Algorithmus mit Priority Queue

- ▶ Die Initialisierung hat eine Laufzeit in O(V).
- Die Methode visit() wird für jeden Knoten maximal einmal aufgerufen. Denn der Aufruf geschieht nur für unmarkierte Knoten, der sodann in der Methode markiert wird.
- ▶ Daher gelangt jede Kante höchstens einmal in die Warteschlange.
- Die Methoden isEmpty(), poll() und add() der Priority Queue werden also höchstens E-mal aufgerufen.
- Die Methoden isEmpty() und poll() haben konstante Laufzeit.
- ▶ Da höchstens E Elemente (Kanten) in die Warteschlange eingefügt werden, hat add() eine Laufzeit in $O(\log E)$, siehe Vorlesung #3.
- ▶ Insgesamt ergibt sich eine Laufzeit in $O(E \log E)$. Da wir den Graphen als zusammenhängend angenommen haben, gilt $E \ge V 1$.

TUB AlgoDat 2019

□ 18 ▷

Verbesserte Implementierung mit indizierter Vorrangwarteschlange

- ► Der Prim Algorithmus kann durch Verwendung einer indizierten Vorrangwarteschlange beschleunigt werden.
- ▶ Bei der bisherigen Implementierung gelangen alle kreuzenden Kanten in die Warteschlange und verbleiben dort, bis sie abgerufen werden.

TUB AlgoDat 2019

□ 19 □

Verbesserte Implementierung mit indizierter Vorrangwarteschlange

- ► Der Prim Algorithmus kann durch Verwendung einer indizierten Vorrangwarteschlange beschleunigt werden.
- ▶ Bei der bisherigen Implementierung gelangen alle kreuzenden Kanten in die Warteschlange und verbleiben dort, bis sie abgerufen werden.
- ▶ Dies ist ineffizient: Sobald eine kürzere kreuzende Kante zu einem Knoten gefunden wurde, sind alle längeren kreuzenden Kanten irrelevant. Sie kommen für die Auswahl nicht in Frage, siehe Schnitteigenschaft, S. 10.

TUB AlgoDat 2019

□ 19 □

Verbesserte Implementierung mit indizierter Vorrangwarteschlange

- ► Der Prim Algorithmus kann durch Verwendung einer indizierten Vorrangwarteschlange beschleunigt werden.
- ▶ Bei der bisherigen Implementierung gelangen alle kreuzenden Kanten in die Warteschlange und verbleiben dort, bis sie abgerufen werden.
- ▶ Dies ist ineffizient: Sobald eine kürzere kreuzende Kante zu einem Knoten gefunden wurde, sind alle längeren kreuzenden Kanten irrelevant. Sie kommen für die Auswahl nicht in Frage, siehe Schnitteigenschaft, S. 10.
- ▶ Daher reicht es, für jeden Knoten, die kürzeste Kante unter den bisher bekannten Kanten zu speichern, bzw. deren Gewicht: knoten-indiziertes Array weight0fCE.

▶ Dadurch wird auch der Speicherbedarf von O(E) auf O(V) reduziert.

TUB AlgoDat 2019

□ 19 □

Implementation von Prims Algorithmus mit IndexPQ

```
public class MSTPrim
   { //Gewicht der min kreuzenden Kante zum Knoten
     protected double[] weightOfCE;
     protected IndexPQ<Double> pg;
5
     public MSTPrim(WeightedGraph G) {
6
       marked = new boolean[G.V()];
       parent = new int[G.V()];
       weight0fCE = new double[G.V()];
       for (int v = 0; v < G.V(); v++) {
10
         weight0fCE[v] = Double.POSITIVE_INFINITY;
11
12
13
       weight0fCE[s] = 0:
       pq = new IndexP0 < Double > (G, V(), -1):
14
       pq.add(s, weightOfCE[s]);
15
16
17
       while (!pq.isEmpty()) {
         int v = pq.poll();
18
         visit(G, v);
19
20
21
```

```
public void visit(WeightedGraph G, int v) {
  marked[v] = true;
                                                 23
  for (Edge e : G.incident(v)) {
                                                 24
    int w = e.other(v);
                                                 25
    if (marked[w])
                                                 26
      continue;
    if (e.weight() < weight0fCE[w]) {</pre>
                                                 28
      parent[w] = v;
                                                 29
      weight0fCE[w] = e.weight();
                                                 30
      if (pg.contains(w)) {
                                                 31
        pg.change(w, weight0fCE[w]);
                                                 32
      } else {
                                                 33
        pq.add(w, weight0fCE[w]);
                                                 35
                                                 36
                                                 37
                                                 38
                                                 39
```

Analyse der Prim Implementation mit indizierter PQ

Korrektheit und Laufzeit des Prim Algorithmus mit IndexPQ

Die Implementation des Prim Algorithmus mit indizierter Vorrangwarteschlange bestimmt den minimalen Spannbaum in einer Laufzeit in $O(E \log V)$ und mit Speicherbedarf in O(V).

Beweis.

- Die Korrektheit ergibt sich wie zuvor. Laufzeit:
- ▶ Die Methode visit() wird für jeden Knoten maximal einmal aufgerufen.
- ▶ Die for Schleife in visit() wird also höchstens E-mal durchlaufen.

TUB AlgoDat 2019

⊲ 21 ⊳

Analyse der Prim Implementation mit indizierter PQ

Korrektheit und Laufzeit des Prim Algorithmus mit IndexPQ

Die Implementation des Prim Algorithmus mit indizierter Vorrangwarteschlange bestimmt den minimalen Spannbaum in einer Laufzeit in $O(E \log V)$ und mit Speicherbedarf in O(V).

Beweis.

- ▶ Die Korrektheit ergibt sich wie zuvor. Laufzeit:
- ▶ Die Methode visit() wird für jeden Knoten maximal einmal aufgerufen.
- ▶ Die for Schleife in visit() wird also höchstens E-mal durchlaufen.
- ▶ Die Warteschlange enthält jeden Knoten höchstens einmal. Für schon vorhandene Knoten wird nur ggf. das Gewicht aktualisiert.
- Daher ist die Laufzeit jedes Aufrufs der PQ-Methoden change() und add() in $O(\log V)$. Bei einer *indizierten* PQ hat contains() konstante Laufzeit.

▶ Insgesamt erhalten wir also eine Laufzeit in $O(E \log V)$.

TUB AlgoDat 2019

⊲ 21 ⊳

Der unbekanntere Kruskal Algorithmus: Reverse-Delete

Der Artikel [Kruskal 1956] enthält außer dem bekannten Kruskal Algorithmus, eine weitere Variante: reverse-delete. Sie funktioniert so:

- ▶ Beginne mit dem gegebenen Graphen.
- ▶ Durchlaufe die Kanten in der Reihenfolge nach absteigendem Gewicht.

Der unbekanntere Kruskal Algorithmus: Reverse-Delete

Der Artikel [Kruskal 1956] enthält außer dem bekannten Kruskal Algorithmus, eine weitere Variante: reverse-delete. Sie funktioniert so:

- ▶ Beginne mit dem gegebenen Graphen.
- ▶ Durchlaufe die Kanten in der Reihenfolge nach absteigendem Gewicht.
- ▶ Falls der Graph durch Entfernen der Kante zusammenhängend bleibt, entferne sie.
- Andernfalls erhalte sie und fahre mit der nächsten Kante fort bis alle Kanten durchlaufen wurden.

Der unbekanntere Kruskal Algorithmus: Reverse-Delete

Der Artikel [Kruskal 1956] enthält außer dem bekannten Kruskal Algorithmus, eine weitere Variante: reverse-delete. Sie funktioniert so:

- ▶ Beginne mit dem gegebenen Graphen.
- ▶ Durchlaufe die Kanten in der Reihenfolge nach absteigendem Gewicht.
- ▶ Falls der Graph durch Entfernen der Kante zusammenhängend bleibt, entferne sie.
- Andernfalls erhalte sie und fahre mit der nächsten Kante fort bis alle Kanten durchlaufen wurden.
- ► Eine effiziente Implementierung insbesondere des Tests auf Zusammenhang ist komplex, daher besprechen wir den Algorithmus nicht weiter.
- Nur der Hinweis: Mit [Thorup 2000] erreicht man eine Laufzeit in $O(E \log V(\log \log V)^3)$.

Kruskals Algorithmus für minimale Spannbäume

- Der prominente Kruskal Algorithmus geht umgekeht vor.
- ▶ Die Kanten werden in der Reihenfolge nach aufsteigendem Gewicht durchlaufen.

TUB AlgoDat 2019

⊲ 23 ⊳

Kruskals Algorithmus für minimale Spannbäume

- Der prominente Kruskal Algorithmus geht umgekeht vor.
- ▶ Die Kanten werden in der Reihenfolge nach aufsteigendem Gewicht durchlaufen.
- ▶ In jedem Schritt wird die aktuelle Kante ggf. zu einer Menge *MST* hinzugefügt, die am Ende den minimalen Spannbaum bildet.
- ► Es wird geprüft, ob das Hinzufügen der Kante zu einem Zyklus in *MST* führt. Nur, wenn dies nicht der Fall ist, wird sie ausgewählt.

TUB AlgoDat 2019

□ 23 ▷

Kruskals Algorithmus für minimale Spannbäume

- Der prominente Kruskal Algorithmus geht umgekeht vor.
- ▶ Die Kanten werden in der Reihenfolge nach aufsteigendem Gewicht durchlaufen.
- ▶ In jedem Schritt wird die aktuelle Kante ggf. zu einer Menge *MST* hinzugefügt, die am Ende den minimalen Spannbaum bildet.
- ► Es wird geprüft, ob das Hinzufügen der Kante zu einem Zyklus in *MST* führt. Nur, wenn dies nicht der Fall ist, wird sie ausgewählt.
- Der Ablauf ist völlig anders, als bei den bisher besprochenen Algorithmen. Die ausgewählten Kanten bilden zunächst keinen Baum, der schrittweise vergrößert wird. Daher können die Kanten beim Ablauf nicht wie bisher in einem Knoten-indizierten parent Array gespeichert werden.

TUB AlgoDat 2019

□ 23 ▷

Überlegungen zur Implementierung von Kruskals Algorithmus

- ▶ Obwohl der Algorithmus einfach zu implementieren aussieht, gibt es einen Haken für eine halbwegs effiziente Lösung.
- ▶ Das Problem ist der Test, ob eine Kante (v, w) einen Zyklus erzeugen würde, der in jedem Schritt durchgeführt werden muss.
- ▶ Die Prüfung auf Zyklen mit Tiefensuche hat eine Laufzeit in O(V + E).

TUB AlgoDat 2019

⊲ 24 ⊳

Überlegungen zur Implementierung von Kruskals Algorithmus

- Obwohl der Algorithmus einfach zu implementieren aussieht, gibt es einen Haken für eine halbwegs effiziente Lösung.
- ▶ Das Problem ist der Test, ob eine Kante (v, w) einen Zyklus erzeugen würde, der in jedem Schritt durchgeführt werden muss.
- ▶ Die Prüfung auf Zyklen mit Tiefensuche hat eine Laufzeit in O(V + E).
- ▶ Hier ginge der Test einfacher, da wir nur mit Tiefensuchen prüfen müssen, ob w von v aus erreichbar ist. Dies hat eine Laufzeit in O(V).
- ▶ Da bei Kruskal dieser Test für jede Kante, also E-mal, durchgeführt werden muss, ergibt sich eine Gesamtlaufzeit von O(VE): zu langsam!

Überlegungen zur Implementierung von Kruskals Algorithmus

- Obwohl der Algorithmus einfach zu implementieren aussieht, gibt es einen Haken für eine halbwegs effiziente Lösung.
- ▶ Das Problem ist der Test, ob eine Kante (v, w) einen Zyklus erzeugen würde, der in jedem Schritt durchgeführt werden muss.
- ▶ Die Prüfung auf Zyklen mit Tiefensuche hat eine Laufzeit in O(V + E).
- ▶ Hier ginge der Test einfacher, da wir nur mit Tiefensuchen prüfen müssen, ob w von v aus erreichbar ist. Dies hat eine Laufzeit in O(V).
- ▶ Da bei Kruskal dieser Test für jede Kante, also E-mal, durchgeführt werden muss, ergibt sich eine Gesamtlaufzeit von O(VE): zu langsam!
- ▶ Der Graph, der während des Kruskal Algorithmus auf Zyklen geprüft wird, ändert sich bei jedem Schritt nur um eine Kante.
- Anstatt die Zyklenprüfung jedes Mal naiv neu zu starten, können wir schrittweise Strukturen aufbauen, die eine schnelle Prüfung ermöglichen.

Dynamisch Prüfung auf Zyklen mit UnionFind

- ▶ Die Frage, ob durch Hinzufügung der Kante (v, w) ein Zyklus entsteht, ist äquivalent zu der Frage, ob v und w bereits in derselben Zusammenhangskomponente liegen.
- Bei Benutzung der Identifikation von Zusammenhangskomponenten mit Tiefensuche (Vorlesung #07) wäre in Bezug auf Laufzeit nichts gewonnen.

Dynamisch Prüfung auf Zyklen mit UnionFind

- ▶ Die Frage, ob durch Hinzufügung der Kante (v, w) ein Zyklus entsteht, ist äquivalent zu der Frage, ob v und w bereits in derselben Zusammenhangskomponente liegen.
- ▶ Bei Benutzung der Identifikation von Zusammenhangskomponenten mit Tiefensuche (Vorlesung #07) wäre in Bezug auf Laufzeit nichts gewonnen.
- ► Wir führen daher die Datenstruktur UnionFind ein, die für die dynamische Verwaltung von Zusammenhangskomponenten bestens geeignet ist:

API für Union-Find (dynamische Verwaltung von Zusammenhangskomponenten)		
public class UnionFind		
	UnionFind(int V)	Initialisiert V Komponenten, jeweils mit einem Knoten $0, \dots, V-1$
void	union(int v, int w)	Verbindet die Komponenten, die v und w enthalten
int	find(int v)	ID der Komponente, die v enthält
boolean	<pre>connected(int v, int w)</pre>	Sind v und w in derselben Komponente?
int	count()	Anzahl der Komponenten

Kruskals Algorithmus als Pseudocode

- Die Implementierung von UnionFind folgt im letzten Teil der Vorlesung.
- Wir setzen diese nun voraus und fahren mit Kruskal fort.

Listing 2: Algorithmus von Kruskal mit UnionFind

```
UF: UnionFind(V)  // Initialisierung mit einzelnen Komponenten für jeden Knoten
MST ←Ø  // Kanten des minimalen Spannbaums (z.B. als Queue)
sortiere Kanten E aufsteigend nach Gewicht
for (v,w) ∈ E in dieser Reihenfolge
if UF.find(v) ≠ UF.find(w) then
   UF.union(v, w)
   add (v,w) to MST
end
end
```

Kruskals Algorithmus als Pseudocode

- Die Implementierung von UnionFind folgt im letzten Teil der Vorlesung.
- Wir setzen diese nun voraus und fahren mit Kruskal fort.

Listing 2: Algorithmus von Kruskal mit UnionFind

```
UF: UnionFind(V)  // Initialisierung mit einzelnen Komponenten für jeden Knoten

MST ←Ø  // Kanten des minimalen Spannbaums (z.B. als Queue)

sortiere Kanten E aufsteigend nach Gewicht

for (v,w) ∈ E in dieser Reihenfolge

if UF.find(v) ≠ UF.find(w) then

UF.union(v, w)

add (v,w) to MST

end

end
```

Das Durchlaufen der Kanten aufsteigend nach Gewicht kann z.B. über eine minPQ implementiert werden.

Korrektheit von Kruskals Algorithmus

Korrektheit des Kruskal Algorithmus

Der Algorithmus von Kruskal in Listing 2 bestimmt den minimalen Spannbaum.

Beweis.

- ▶ Die Korrektheit folgt aus dem Beweis zum allgemeinen Ansatz, S. 13:
- Jede Kante (v, w), die hinzugefügt wird, ist eine kreuzende Kante des Schnittes, der durch alle mit v verbundenen Knoten definiert wird, also die entsprechende Zusammenhangskomponente von Union-Find.
- ▶ Diese Kante (v, w) ist tatsächliche eine kreuzende Kante, da v zu der Menge gehört und w nicht, denn $UF.find(v) \neq UF.find(w)$.

TUB AlgoDat 2019

d 27 ⊳

Korrektheit von Kruskals Algorithmus

Korrektheit des Kruskal Algorithmus

Der Algorithmus von Kruskal in Listing 2 bestimmt den minimalen Spannbaum.

Beweis.

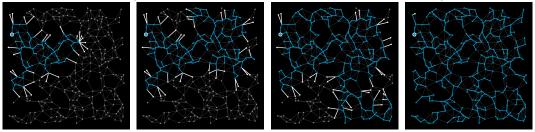
- ▶ Die Korrektheit folgt aus dem Beweis zum allgemeinen Ansatz, S. 13:
- Jede Kante (v, w), die hinzugefügt wird, ist eine kreuzende Kante des Schnittes, der durch alle mit v verbundenen Knoten definiert wird, also die entsprechende Zusammenhangskomponente von Union-Find.
- ▶ Diese Kante (v, w) ist tatsächliche eine kreuzende Kante, da v zu der Menge gehört und w nicht, denn $UF.find(v) \neq UF.find(w)$.
- ▶ Unter den kreuzenden Kanten hat (v, w) minimales Gewicht, da alle anderen kreuzenden Kanten später in der Sortierung vorkommen.

TUB AlgoDat 2019

□ 27 ▷

Reihenfolge der Knotenauswahl bei Prim und Kruskal

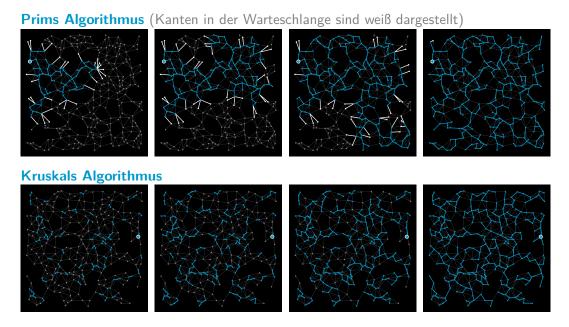
Prims Algorithmus (Kanten in der Warteschlange sind weiß dargestellt)



TUB AlgoDat 2019

⊲ 28 ⊳

Reihenfolge der Knotenauswahl bei Prim und Kruskal



TUB AlgoDat 2019

⊲ 28 ⊳

Union-Find: Dynamische Zusammenhangskomponenten

► Union-Find startet mit *N* separaten Knoten, jeder in einer eigenen Zusammenhangskomponente.







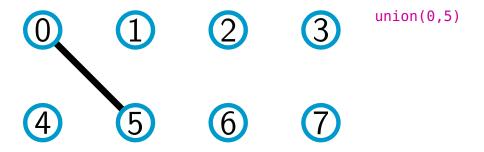






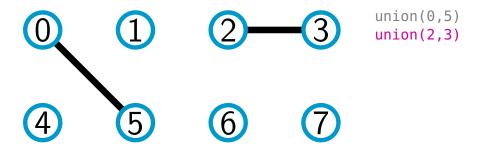
Union-Find: Dynamische Zusammenhangskomponenten

- ▶ Union-Find startet mit *N* separaten Knoten, jeder in einer eigenen Zusammenhangskomponente.
- Mit union() werden zwei Komponenten verbunden.

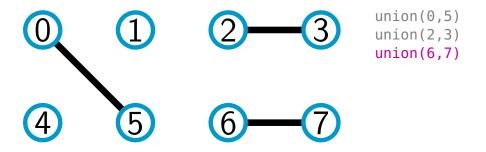


Union-Find: Dynamische Zusammenhangskomponenten

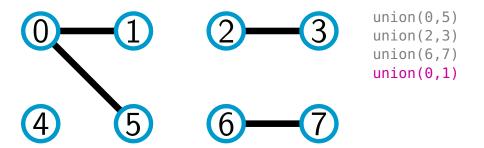
- ▶ Union-Find startet mit *N* separaten Knoten, jeder in einer eigenen Zusammenhangskomponente.
- Mit union() werden zwei Komponenten verbunden.



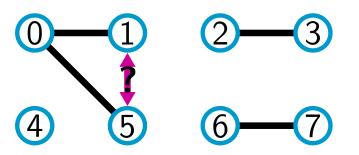
- ▶ Union-Find startet mit *N* separaten Knoten, jeder in einer eigenen Zusammenhangskomponente.
- Mit union() werden zwei Komponenten verbunden.



- ▶ Union-Find startet mit *N* separaten Knoten, jeder in einer eigenen Zusammenhangskomponente.
- Mit union() werden zwei Komponenten verbunden.

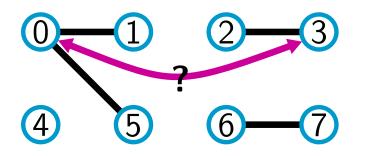


- ▶ Union-Find startet mit *N* separaten Knoten, jeder in einer eigenen Zusammenhangskomponente.
- Mit union() werden zwei Komponenten verbunden.
- ▶ Mit connected() wird geprüft, ob zwei Knoten zusammenhängen.



```
union(0,5)
union(2,3)
union(6,7)
union(0,1)
connected(1,5)? true
```

- ▶ Union-Find startet mit *N* separaten Knoten, jeder in einer eigenen Zusammenhangskomponente.
- Mit union() werden zwei Komponenten verbunden.
- ▶ Mit connected() wird geprüft, ob zwei Knoten zusammenhängen.

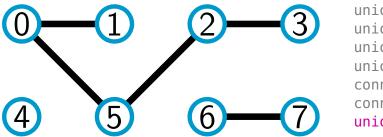


```
union(0,5)
union(2,3)
union(6,7)
union(0,1)
connected(1,5)? true
connected(0,3)? false
```

TUB AlgoDat 2019

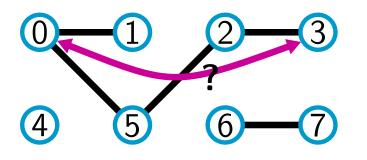
□ 29 ▷

- ▶ Union-Find startet mit *N* separaten Knoten, jeder in einer eigenen Zusammenhangskomponente.
- Mit union() werden zwei Komponenten verbunden.
- ▶ Mit connected() wird geprüft, ob zwei Knoten zusammenhängen.



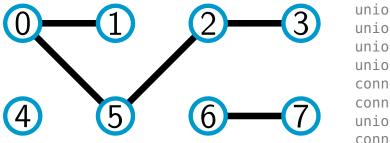
```
union(0,5)
union(2,3)
union(6,7)
union(0,1)
connected(1,5)? true
connected(0,3)? false
union(5,2)
```

- ▶ Union-Find startet mit *N* separaten Knoten, jeder in einer eigenen Zusammenhangskomponente.
- Mit union() werden zwei Komponenten verbunden.
- ▶ Mit connected() wird geprüft, ob zwei Knoten zusammenhängen.



```
union(0,5)
union(2,3)
union(6,7)
union(0,1)
connected(1,5)? true
connected(0,3)? false
union(5,2)
connected(0,3)? true
```

- ▶ Union-Find startet mit *N* separaten Knoten, jeder in einer eigenen Zusammenhangskomponente.
- Mit union() werden zwei Komponenten verbunden.
- ▶ Mit connected() wird geprüft, ob zwei Knoten zusammenhängen.



union(0,5)
union(2,3)
union(6,7)
union(0,1)
connected(1,5)? true
connected(0,3)? false
union(5,2)
connected(0,3)? true

▶ Wir werden unterschiedliche Implementierungsansätze besprechen.

► Zunächst wählen wir eine Variante, bei der find(), bzw. connected() möglichst schnell ist.

TUB AlgoDat 2019

⊲ 30 ⊳

- ► Zunächst wählen wir eine Variante, bei der find(), bzw. connected() möglichst schnell ist.
- Wir verwenden ein Knoten-indiziertes Array id, wie bei der Implementation der Zusammenhangskomponenten.
- ► Eine connected(v,w) Anfrage entspricht dem Vergleich id[v] == id[w].



1

2

3

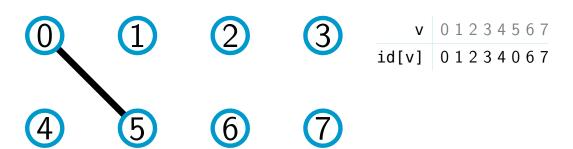


(5)

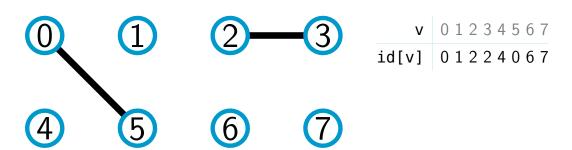
6

7

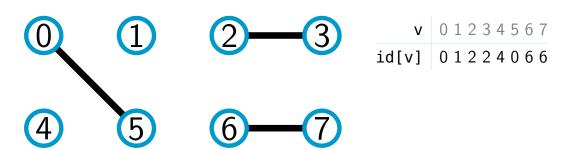
- ► Zunächst wählen wir eine Variante, bei der find(), bzw. connected() möglichst schnell ist.
- Wir verwenden ein Knoten-indiziertes Array id, wie bei der Implementation der Zusammenhangskomponenten.
- ► Eine connected(v,w) Anfrage entspricht dem Vergleich id[v] == id[w].



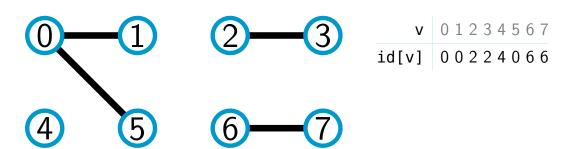
- ► Zunächst wählen wir eine Variante, bei der find(), bzw. connected() möglichst schnell ist.
- Wir verwenden ein Knoten-indiziertes Array id, wie bei der Implementation der Zusammenhangskomponenten.
- ► Eine connected(v,w) Anfrage entspricht dem Vergleich id[v] == id[w].



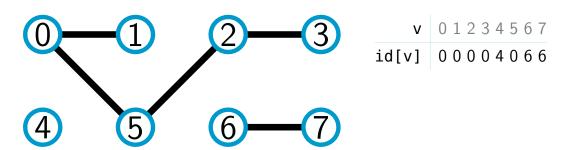
- ► Zunächst wählen wir eine Variante, bei der find(), bzw. connected() möglichst schnell ist.
- Wir verwenden ein Knoten-indiziertes Array id, wie bei der Implementation der Zusammenhangskomponenten.
- ► Eine connected(v,w) Anfrage entspricht dem Vergleich id[v] == id[w].



- ► Zunächst wählen wir eine Variante, bei der find(), bzw. connected() möglichst schnell ist.
- Wir verwenden ein Knoten-indiziertes Array id, wie bei der Implementation der Zusammenhangskomponenten.
- ► Eine connected(v,w) Anfrage entspricht dem Vergleich id[v] == id[w].



- ► Zunächst wählen wir eine Variante, bei der find(), bzw. connected() möglichst schnell ist.
- Wir verwenden ein Knoten-indiziertes Array id, wie bei der Implementation der Zusammenhangskomponenten.
- ► Eine connected(v,w) Anfrage entspricht dem Vergleich id[v] == id[w].



```
public class UnionFind { // quick-find
 private int[] id;
 private int count;
 public UnionFind(int V) {
    count = V;
    id = new int[V];
   for (int v = 0; v < V; v++) {
      id[v] = v;
  public int count()
  { return count; }
  public int find(int v)
  { return id[v]; }
  public boolean connected(int v, int w)
  { return id[v] == id[w]; }
```

```
public class UnionFind { // quick-find
 private int[] id;
 private int count;
  public UnionFind(int V) {
    count = V;
    id = new int[V];
    for (int v = 0; v < V; v++) {
      id[v] = v:
  public int count()
  { return count; }
  public int find(int v)
  { return id[v]; }
  public boolean connected(int v, int w)
  { return id[v] == id[w]; }
```

```
public void union(int v, int w) {
    if (connected(v, w))
        return;
    int wid = id[w];
    for (int u = 0; u < id.length; u++) {
        if (id[u] == wid) {
            id[u] = id[v];
        }
    }
    count--;
}</pre>
```

Implementation von Union-Find mit quick-find

```
public class UnionFind { // quick-find
 private int[] id;
 private int count;
 public UnionFind(int V) {
    count = V;
    id = new int[V];
    for (int v = 0; v < V; v++) {
      id[v] = v:
  public int count()
  { return count; }
  public int find(int v)
  { return id[v]; }
  public boolean connected(int v, int w)
  { return id[v] == id[w]; }
```

```
public void union(int v, int w) {
   if (connected(v, w))
      return;
   int wid = id[w];
   for (int u = 0; u < id.length; u++) {
      if (id[u] == wid) {
        id[u] = id[v];
      }
   }
   count--;
   }
}</pre>
```

- ▶ Die Methoden find() und connected() sind sehr schnell, O(1).
- ► Aber union() muss das ganze Feld durchsuchen, also *O*(*V*).
- Daher ist dieser Ansatz nicht geeignet.

Implementierung optimiert für schnelles Zusammenlegen (quick-union)

- ▶ Um eine schnellere union() Operation zu realisieren, können wir eine Baumstruktur für jede Komponente nutzen.
- Dabei enthält id[v] die Nummer eines anderen Knotens derselben Komponente (Verweis auf Elternknoten), oder seine eigene Nummer. Daher nennen wir die Variable jetzt parent.
- ► Ein Knoten jeder Komponente verweist per parent auf sich selbst. Dieser wird Wurzel genannt.

Implementierung optimiert für schnelles Zusammenlegen (quick-union)

- ► Um eine schnellere union() Operation zu realisieren, können wir eine Baumstruktur für jede Komponente nutzen.
- Dabei enthält id[v] die Nummer eines anderen Knotens derselben Komponente (Verweis auf Elternknoten), oder seine eigene Nummer. Daher nennen wir die Variable jetzt parent.
- ► Ein Knoten jeder Komponente verweist per parent auf sich selbst. Dieser wird Wurzel genannt.
- ▶ Bei diesem Ansatz ist union(v,w) sehr einfach zu realisieren: Man lässt die Wurzel der w-Komponente auf die Wurzel der v-Komponente verweisen.
- ► Man könnte auch die Wurzel der w-Komponente auf v verweisen lassen, aber das führt zu hohen Bäumen und damit zu einer schlechteren Laufzeit.

Implementierung optimiert für schnelles Zusammenlegen (quick-union)

- ► Um eine schnellere union() Operation zu realisieren, können wir eine Baumstruktur für jede Komponente nutzen.
- ▶ Dabei enthält id[v] die Nummer eines anderen Knotens derselben Komponente (Verweis auf Elternknoten), oder seine eigene Nummer. Daher nennen wir die Variable jetzt parent.
- ► Ein Knoten jeder Komponente verweist per parent auf sich selbst. Dieser wird Wurzel genannt.
- ▶ Bei diesem Ansatz ist union(v,w) sehr einfach zu realisieren: Man lässt die Wurzel der w-Komponente auf die Wurzel der v-Komponente verweisen.
- ► Man könnte auch die Wurzel der w-Komponente auf v verweisen lassen, aber das führt zu hohen Bäumen und damit zu einer schlechteren Laufzeit.
- ► Im Gegenzug ist nun find() aufwändiger: Man muss über das Elternknoten-Array parent die Wurzel suchen.

```
1 // UnionFind mit lazy quick-union
       gebenüber der guick-find Version
3 // sind nur folgende Methoden anders:
    public int find(int v)
       while (v != parent[v])
6
         v = parent[v];
       return v;
8
9
10
     public void union(int v, int w)
11
12
       int vRoot = find(v);
13
       int wRoot = find(w);
14
       if (vRoot == wRoot)
         return;
16
17
       parent[wRoot] = vRoot;
18
       count - -;
19
20
```

Implementation von Union-Find mit quick-union (lazy union-find)

```
1 // UnionFind mit lazy quick-union
       gebenüber der guick-find Version
       sind nur folgende Methoden anders:
    public int find(int v)
       while (v != parent[v])
         v = parent[v];
       return v:
8
10
    public void union(int v, int w)
11
12
      int vRoot = find(v):
13
       int wRoot = find(w);
14
       if (vRoot == wRoot)
         return;
       parent[wRoot] = vRoot;
18
       count - -;
19
20
```

- Die Methode find() hat im schlechtesten Fall eine Laufzeit in O(V).
- Auch wenn das eigentliche Zusammenlegen zweier Komponenten schnell geht (Zeile 18), bringt es im worst case keinen Vorteil, da zunächst per langsamen find() die Wurzeln der Komponenten gesucht werden müssen.
- Also geht die Suche nach einem geeigneten Ansatz weiter.

Union-Find mit flacheren Bäumen (eager union-find)

- Die Fälle mit schlechter Laufzeit bei dem quick-union Ansatz treten auf, wenn größere Komponenten an kleinere angehängt werden, weil dabei der entstehende Baum höher wird.
- Dem Höhenwachstum der Bäume kann dadurch begegnet werden, dass immer der kleinere an den größeren Baum angehängt wird.
- Dazu speichern wir die Höhe jedes Baums in dem Knoten-indizierten Array ht.

```
public class UnionFind { // flache Bäume
    private int[] parent;
    private int[] ht:
    private int count;
5
    public UnionFind(int V) {
6
       count = V;
7
      parent = new int[V];
8
      ht = new int[V]:
9
       for (int v = 0; v < V; v++) {
         parent[v] = v;
        ht[v] = 0:
12
13
14
15
  // count, connected und find wie oben
```

```
public void union(int v, int w)
                                           18
  int vRoot = find(v);
                                           19
  int wRoot = find(w);
                                           20
  if (vRoot == wRoot)
    return;
  if (ht[wRoot] < ht[vRoot]) {</pre>
                                           24
    parent[wRoot] = vRoot;
                                           25
 } else {
                                           26
    parent[vRoot] = wRoot;
    if (ht(vRoot) == ht[wRoot]) {
                                           28
      ht[wRoot]++;
                                           29
                                           30
                                           31
  count - -;
                                           32
                                           33
                                           34
```

Laufzeit von Union-Find mit flachen Bäumen

Maximale Höhe der Bäume in eager Union-Find

Die Bäume in *eager* Union-Find (Seite 35) haben maximal die Höhe $\lg V$. (\lg bezeichnet den Logarithmus zur Basis 2.)

Beweis. Wir zeigen durch Induktion nach n, dass ein Baum mit n Knoten in eager Union-Find höchstens die Höhe $\lg n$ hat.

TUB AlgoDat 2019

⊲ 36 ⊳

Laufzeit von Union-Find mit flachen Bäumen

Maximale Höhe der Bäume in eager Union-Find

Die Bäume in eager Union-Find (Seite 35) haben maximal die Höhe $\lg V$. (\lg bezeichnet den Logarithmus zur Basis 2.)

Beweis. Wir zeigen durch Induktion nach n, dass ein Baum mit n Knoten in eager Union-Find höchstens die Höhe $\lg n$ hat.

- Werden zwei Bäume mit unterschiedlichen Höhen zusammengelegt, so hat der entstehende Baum dieselbe Höhe, wie der größere der beiden ursprünglichen Bäume. Daher folgt die IB direkt aus der IV.
- ▶ Betrachten wir also den Fall, dass zwei Bäume mit k_0 und k_1 Knoten und Höhe h zu einem Baum mit $k_0 + k_1$ Knoten vereint werden.

Laufzeit von Union-Find mit flachen Bäumen

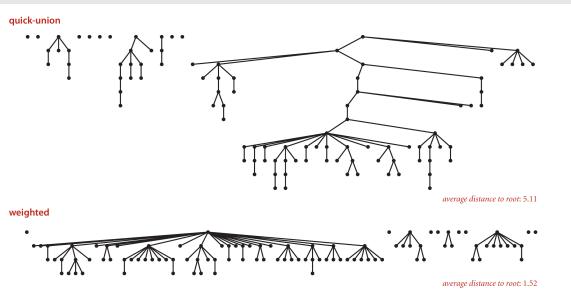
Maximale Höhe der Bäume in eager Union-Find

Die Bäume in eager Union-Find (Seite 35) haben maximal die Höhe $\lg V$. (\lg bezeichnet den Logarithmus zur Basis 2.)

Beweis. Wir zeigen durch Induktion nach n, dass ein Baum mit n Knoten in eager Union-Find höchstens die Höhe $\lg n$ hat.

- Werden zwei Bäume mit unterschiedlichen Höhen zusammengelegt, so hat der entstehende Baum dieselbe Höhe, wie der größere der beiden ursprünglichen Bäume. Daher folgt die IB direkt aus der IV.
- ▶ Betrachten wir also den Fall, dass zwei Bäume mit k_0 und k_1 Knoten und Höhe h zu einem Baum mit $k_0 + k_1$ Knoten vereint werden.
- Nach IV gilt $h \le \lg k$ für $k = \min(k_0, k_1)$. Durch das Anhängen des einen Baumes an die Wurzel des anderen Baumes, steigt die Höhe um eins.
- ▶ Also ist für den neuen Baum die Höhe maximal $1 + h \le 1 + \lg k = \lg(2k) \le \lg(k_0 + k_1)$. □

Gegenüberstellung von lazy und eager Union-Find



 $Quick-union\ and\ weighted\ quick-union\ (100\ sites,\ 88\ union\ ()\ operations)$

- Mit eager Union-Find haben wir einen Algorithmus für dynamische Zusammenhangskomponenten mit guter Laufzeit auch im worst case.
- Diese Laufzeitgarantie ist für die Praxis ausreichend, aber es geht noch besser!

TUB AlgoDat 2019

□ 38 ▷

- Mit *eager* Union-Find haben wir einen Algorithmus für dynamische Zusammenhangskomponenten mit guter Laufzeit auch im *worst case*.
- ▶ Diese Laufzeitgarantie ist für die Praxis ausreichend, aber es geht noch besser!
- Man kann bei der find() Operation die Baumstruktur nebenbei verbessern.
- 'Verbessern' heißt in unserem Fall, die Bäume möglichst flach zu halten.

- Mit eager Union-Find haben wir einen Algorithmus für dynamische Zusammenhangskomponenten mit guter Laufzeit auch im worst case.
- ▶ Diese Laufzeitgarantie ist für die Praxis ausreichend, aber es geht noch besser!
- ▶ Man kann bei der find() Operation die Baumstruktur nebenbei verbessern.
- 'Verbessern' heißt in unserem Fall, die Bäume möglichst flach zu halten.
- ▶ Bei der sogenannten **Pfadkompression** nutzt man das Iterieren zu der Wurzel eines Baumes während find() dazu, alle durchlaufenen Knoten näher an die Wurzel zu bringen:

- Mit eager Union-Find haben wir einen Algorithmus für dynamische Zusammenhangskomponenten mit guter Laufzeit auch im worst case.
- ▶ Diese Laufzeitgarantie ist für die Praxis ausreichend, aber es geht noch besser!
- Man kann bei der find() Operation die Baumstruktur nebenbei verbessern.
- ▶ 'Verbessern' heißt in unserem Fall, die Bäume möglichst flach zu halten.
- Bei der sogenannten Pfadkompression nutzt man das Iterieren zu der Wurzel eines Baumes während find() dazu, alle durchlaufenen Knoten näher an die Wurzel zu bringen:
 - Zweistufig: Bestimme im ersten Durchlauf die Wurzel wie bisher und hänge im zweiten Durchlauf alle Knoten direkt an die Wurzel.
 - Einstufig: Hänge jeden Knoten in der Iteration an seinen Vorvorgänger (Halbierung der Pfadtiefe).

Implementation von Union-Find mit Pfadkompression

```
public class UnionFind //Pfadkompression
    // ... wie eager UnionFind
    // es ändert sich nur find()
5
    public int find(int v) {
6
      while (v != parent[v]) {
         parent[v] = parent[parent[v]];
         v = parent[v];
10
      return v;
12
13 }
```

 Die Laufzeitanalyse dieser Variante ist sehr komplex. Daher benügen wir uns in dieser Vorlesung mit dem Ergebnis.

Laufzeiten der Union-Find Operationen

Wachstumsordnung für V Knoten (worst case)					
Algorithmus	Init	union	find		
Quick-find	$\mathbf{O}(V)$	O(V)	O (1)		
Lazy quick-union	$\mathbf{O}(V)$	O(V)	O(V)		
Eager quick-union	$\mathbf{O}(V)$	$O(\lg V)$	$O(\lg V)$		
Union-Find mit Pfadkompression	O(V)	$\mathbf{O}(\lg^* V)$	$O(\lg^* V)$		

Laufzeiten der Union-Find Operationen

Wachstumsordnung für V Knoten (worst case)					
Algorithmus	Init	union	find		
Quick-find	$\mathbf{O}(V)$	O(V)	O (1)		
Lazy quick-union	$\mathbf{O}(V)$	O(V)	O(V)		
Eager quick-union	$\mathbf{O}(V)$	$O(\lg V)$	$O(\lg V)$		
Union-Find mit Pfadkompression	O(V)	$\boldsymbol{O}(\lg^* V)$	$\mathbf{O}(\lg^* V)$		

▶ Was ist $\lg^*(V)$??

Laufzeiten der Union-Find Operationen

Wachstumsordnung für V Knoten (worst case)				
Algorithmus	Init	union	find	
Quick-find	O(V)	O(V)	O (1)	
Lazy quick-union	O(V)	O(V)	O(V)	
Eager quick-union	O(V)	$O(\lg V)$	$O(\lg V)$	
Union-Find mit Pfadkompression	O(V)	$\boldsymbol{O}(\lg^* V)$	$O(\lg^* V)$	

▶ $\lg^*(V) < 5$

Laufzeiten der Union-Find Operationen

Wachstumsordnung für V Knoten (worst case)			
Algorithmus	Init	union	find
Quick-find	O(V)	O(V)	O (1)
Lazy quick-union	O(V)	O(V)	O(V)
Eager quick-union	O(V)	$O(\lg V)$	$O(\lg V)$
Union-Find mit Pfadkompression $\mathbf{\textit{O}}(V)$ $\mathbf{\textit{O}}(\lg^* V)$ $\mathbf{\textit{O}}(\lg^* V)$			

▶ $\lg^*(V) < 5$ (für V < # Atome im Universum)

Laufzeiten der Union-Find Operationen

Wachstumsordnung für V Knoten (worst case)			
Algorithmus	Init	union	find
Quick-find	$\mathbf{O}(V)$	O(V)	O(1)
Lazy quick-union	$\mathbf{O}(V)$	O(V)	O(V)
Eager quick-union	$\mathbf{O}(V)$	$O(\lg V)$	$\boldsymbol{O}(\lg V)$
Union-Find mit Pfadkompression	$\mathbf{O}(V)$	$\boldsymbol{O}(\lg^* V)$	$\boldsymbol{O}(\lg^* V)$

V	$\lg^* V$
1	0
2	1
4	2
16	3
65536	4
2^{65536}	5

- ▶ $\lg^*(V) < 5$ (für V < # Atome im Universum)

Laufzeiten der Union-Find Operationen

Wachstumsordnung für V Knoten (worst case)				
Algorithmus	Init	union	find	
Quick-find	O(V)	O(V)	O (1)	
Lazy quick-union	O(V)	O(V)	O(V)	
Eager quick-union	O(V)	$O(\lg V)$	$O(\lg V)$	
Union-Find mit Pfadkompression $\mathbf{\textit{O}}(V)$ $\mathbf{\textit{O}}(\lg^*V)$ $\mathbf{\textit{O}}(\lg^*V)$				

V	$\lg^* V$
1	0
2	1
4	2
16	3
65536	4
2^{65536}	5

- ▶ $\lg^*(V) < 5$ (für V < # Atome im Universum)
- ► Für Union-Find mit Pfadkompression gibt es eine noch schärfere Abschätzung mit der inversen Ackermann Funktion.

Laufzeiten für N union/find Operationen bei V Knoten (worst case)		
Algorithmus	Laufzeit	
Quick-find	O(NV)	
Lazy quick-union	O(NV)	
Eager quick-union	$O(V + N \lg V)$	
Union-Find mit Pfadkompression	$O((V+N)\lg^*V)$	

Laufzeiten für N union/find ${f C}$	
Algorithmus	Laufzeit
Quick-find	O(NV)
Lazy quick-union	O(NV)
Eager quick-union	$O(V + N \lg V)$
Union-Find mit Pfadkompression	$O((V+N)\lg^*V)$

▶ Beispiel (passt gerade in heutige Speicher): $V = 10^9$ Knoten und $N = 10^9$ union/find Operationen:

Laufzeiten für N union/find ${f C}$	
Algorithmus	Laufzeit
Quick-find	O(NV)
Lazy quick-union	O(NV)
Eager quick-union	$O(V + N \lg V)$
Union-Find mit Pfadkompression	$O((V+N)\lg^*V)$

- ▶ Beispiel (passt gerade in heutige Speicher): $V = 10^9$ Knoten und $N = 10^9$ union/find Operationen:
- ▶ Reduktion der Laufzeit von 30 Jahren auf 6 Sekunden.

Laufzeiten für N union/find Operationen bei V Knoten (worst case)			
Algorithmus	Laufzeit		
Quick-find	O(NV)		
Lazy quick-union	O(NV)		
Eager quick-union	$O(V + N \lg V)$		
Union-Find mit Pfadkompression	$O((V+N)\lg^*V)$		

- ▶ Beispiel (passt gerade in heutige Speicher): $V = 10^9$ Knoten und $N = 10^9$ union/find Operationen:
- ▶ Reduktion der Laufzeit von 30 Jahren auf 6 Sekunden.
- Es kann keinen linearen Algorithmus geben [Fredman & Saks 1989].

Laufzeit und Speicherbedarf von Kruskals MST Algorithmus

Laufzeit des Kruskal Algorithmus

Der Algorithmus von Kruskal in Listing 2 bestimmt den minimalen Spannbaum in einer worst-case Laufzeit in $O(E \log E)$ und einem Speicherbedarf in O(E).

Wir gehen von einer Implementation mittels einer Vorrangewarteschlange (minPQ) für das nach Gewicht sortierte Durchlaufen der Kanten aus.

Laufzeit und Speicherbedarf von Kruskals MST Algorithmus

Laufzeit des Kruskal Algorithmus

Der Algorithmus von Kruskal in Listing 2 bestimmt den minimalen Spannbaum in einer worst-case Laufzeit in $O(E \log E)$ und einem Speicherbedarf in O(E).

Wir gehen von einer Implementation mittels einer Vorrangewarteschlange (minPQ) für das nach Gewicht sortierte Durchlaufen der Kanten aus.

- ▶ Die Initialisierung der Union-Find Struktur in Zeile 1 benötigt O(V) und das Einfügen der Kanten in eine PQ benötigt O(E).
- ▶ Die *for*-Schleife wird für jede Kante einmal durchlaufen. Also benötigen die poll() Operationen der minPQ insgesamt $O(E \log E)$.

Laufzeit und Speicherbedarf von Kruskals MST Algorithmus

Laufzeit des Kruskal Algorithmus

Der Algorithmus von Kruskal in Listing 2 bestimmt den minimalen Spannbaum in einer worst-case Laufzeit in $O(E \log E)$ und einem Speicherbedarf in O(E).

Wir gehen von einer Implementation mittels einer Vorrangewarteschlange (minPQ) für das nach Gewicht sortierte Durchlaufen der Kanten aus.

- ▶ Die Initialisierung der Union-Find Struktur in Zeile 1 benötigt O(V) und das Einfügen der Kanten in eine PQ benötigt O(E).
- ▶ Die for-Schleife wird für jede Kante einmal durchlaufen. Also benötigen die poll() Operationen der minPQ insgesamt $O(E \log E)$.
- Durch die effiziente Union-Find Implementation fallen die union() und find() Operationen nicht ins Gewicht.
- ▶ Der Speicherbedarf ist proportional zu V für Union-Find und zum Speichern des Spannbaums in MST, und für die PQ ist er proportional zu E.

Bemerkung zur Historie

- ▶ Boruvka hat in seinem Aufsatz wesentliche Ideen für die Algorithmen von Prim und Kruskal bereits 1929 in seinem Artikel erwähnt.
- ▶ Weitere Grundlagen für den Prim Algorithmus wurden von Jarnik 1939 und von Kruskal 1956 veröffentlicht. Prims Veröffentlichung ist von 1961.
- ▶ Bei der Einschätzung der frühen Ansätze ist zu berücksichtigen, dass damals viele der effizienten Datentypen wie Vorrangwarteschlagen noch nicht bekannt waren.

Effizientere Weiterentwicklungen

- Fredman-Tarjan 1984: Prim mit Fibonacchi Heap: $O(E + V \log V)$
- ▶ Chazelle 1997, 2000: Laufzeit sehr nah an O(E), aber für die Praxis zu kompliziert.

 Karger-Klein-Tarjan 1995: Randomisierter Algorithmus mit linearer Laufzeit (im Erwartungswert).

Folgende Fragen sollten Sie beantworten können

- Wozu dient Union-Find? Was ist der Unterschied zu dem DFS-basierten Identifizieren von Zusammenhangskomponenten?
- Was ist Prims und Kruskals Algorithmus gemeinsam?
- Worin unterscheidenen sie sich? (Funktionsprinzip erklären)

Literatur I

Generell:

- Segdewick R & Wayne K, Algorithmen: Algorithmen und Datenstrukturen, Pearson Studium, 4. Auflage, 2014. ISBN: 978-3868941845; in Teilen auch auf http://www.cs.princeton.edu/IntroAlgsDS
- ► TH Cormen, CE Leiserson, R Rivest, C Stein, *Algorithmen Eine Einführung*. De Gruyter Oldenbourg, 4. Auflage; 2013. ISBN: 978-3486748611

Originalveröffentlichungen Minimale Spannbäume:

- ▶ Nešetřil J, Milková E, Nešetřilová H. *Otakar Borůvka on minimum spanning tree problem translation of both the 1926 papers*, comments, history. Discrete mathematics. 2001 Apr 28;233(1-3):3-6.
- ► Kruskal JB. On the shortest spanning subtree of a graph and the traveling salesman problem. Proceedings of the American Mathematical society. 1956;7(1):48-50.

Literatur II

- ▶ Prim RC. Shortest connection networks and some generalizations. Bell Labs Technical Journal. 1957 Nov 1;36(6):1389-401.
- ▶ Thorup M. *Near-optimal fully-dynamic graph connectivity*. In: Proceedings of the thirty-second annual ACM symposium on Theory of computing 2000 May 1 (pp. 343-350). ACM.
- ▶ Dijkstra EW. *A note on two problems in connexion with graphs*. Numerische mathematik. 1959 Dec 1;1(1):269-71.
- ► Fredman ML, Tarjan RE. Fibonacci heaps and their uses in improved network optimization algorithms. Journal of the ACM (JACM). 1987 Jul 1;34(3):596-615.
- Karger DR, Klein PN, Tarjan RE. A randomized linear-time algorithm to find minimum spanning trees. Journal of the ACM (JACM). 1995 Mar 1;42(2):321-8.
- ► Chazelle B. A minimum spanning tree algorithm with inverse-Ackermann type complexity. Journal of the ACM (JACM). 2000 Nov 1;47(6):1028-47.

Literatur III

▶ Pettie S, Ramachandran V. *An optimal minimum spanning tree algorithm*. Journal of the ACM (JACM). 2002 Jan 1;49(1):16-34.

Originalveröffentlichungen Union-Find:

- ► Tarjan RE. Efficiency of a good but not linear set union algorithm. Journal of the ACM (JACM). 1975 Apr 1;22(2):215-25.
- ► Fredman M, Saks M. *The cell probe complexity of dynamic data structures*. In: Proceedings of the twenty-first annual ACM symposium on Theory of computing 1989 Feb 1 (pp. 345-354). ACM.

Bildreferenzen I

▶ Die Abbildung auf Seite 37 ist aus dem Buch [Sedgewick & Wayne 2014, S. 254].

Index

API gewichtete Kante, 4 kantengewichteter Graph, 4	Laufzeit, 42 Kruskals Algorithmus Pseudocode, 26	Laufzeit, 18 Prim Algorithmus mit IndexPQ Implementierung, 20
Edge, 4 EdgeWeightedGraph, 4	Laufzeit Kruskal Algorithmus, 42	Korrektheit, 21 Laufzeit, 21
Implementierung	Prim Algorithmus, 18	reverse delete, 22
Prim Algorithmus mit IndexPQ, 20	Prim Algorithmus mit IndexPQ, 21	Schnitt, 9 Schnitteigenschaft, 10
Kantengewichte, 3	minimal kreuzende Kanten, 9	Spannbaum
Korrektheit	Minimaler Spannbaum, 5	Eigenschaften, 7
Allgemeiner MST Ansatz, 13 Prim Algorithmus, 17	reverse delete, 22 MSTPrim, 16, 20	Union-Find Laufzeiten, 41
kreuzende Kanten, 9	Pfadkompression, 38	quick-find, 30
Kruskal Algorithmus, 23	Prim Algorithmus, 15	quick-union, 32
Korrektheit, 27	Korrektheit, 17	UnionFind, 31, 33, 35, 39